

Guion de la présentation

« Les *transformers* (type BERT) encodent-ils la syntaxe d’une langue ? »

Marcos Lahoz Yague — Orange Research, 13 mai 2026

Budget total : 8 minutes (~ 480 s, soit ~ 25 – 30 s par slide en moyenne). Les durées indicatives sont à droite de chaque section.

Slide 1. Titre

(~ 20 s) *Visuel : page de titre, nom et affiliation.*

Bonjour, je suis Marcos Lahoz Yague. Aujourd’hui je vais vous présenter un travail réalisé pendant mon Master 2 à Paris-Saclay, sur la question : les modèles *transformers* de type BERT, encodent-ils la syntaxe du langage ? En huit minutes, je vais vous montrer la méthode, les résultats principaux, et où ce travail pourrait s’étendre vers le doctorat.

Slide 2. Le langage est arborescent

(~ 30 s) *Visuel : phrase « The cat ate the fish » avec son arbre de dépendances.*

Pour répondre à cette question, il faut d’abord se mettre d’accord sur ce que nous appelons « syntaxe ». Dans ce travail, nous prenons une définition précise : l’arbre de dépendances. Chaque mot d’une phrase a exactement *une* tête grammaticale — le mot dont il dépend. La seule exception est la racine, typiquement le verbe principal. Les arêtes peuvent porter des étiquettes — sujet, objet, déterminant — mais comme Hewitt et Manning, nous ne regardons que la *topologie*. C’est cet arbre que nous chercherons à retrouver dans BERT.

Slide 3. Deux métriques sur l’arbre

(~ 35 s) *Visuel : profondeur (badges orange) et distance (chemin orange) sur le même arbre.*

Cette définition nous donne deux quantités numériques naturelles. À gauche : la **profondeur** d’un mot — le nombre d’arêtes jusqu’à la racine. Le verbe principal est à zéro, ses dépendants directs à un. À droite : la **distance** entre deux mots — le nombre d’arêtes du chemin unique qui les relie. Par exemple, « cat » et « fish » sont à distance deux, parce qu’on passe par « ate ». C’est sur la distance que nous concentrons nos expériences — elle donne $O(n^2)$ paires de supervision par phrase contre $O(n)$ pour la profondeur, et c’est aussi sur les distances que la sonde isométrique aura un sens géométrique direct.

Slide 4. BERT comprend-il la syntaxe ?

(~ 30 s) *Visuel : liste des tâches où BERT excelle + diagramme MLM.*

BERT est un modèle *transformer* préentraîné qui a marqué une étape majeure en NLP. Il obtient d’excellents résultats sur de nombreuses tâches : réponse aux questions, inférence textuelle, classification, recherche web. Ce succès suggère que BERT « comprend » le langage. Et pourtant — c’est ce que montre le diagramme à droite — pendant son préentraînement, BERT ne fait qu’une chose : prédire des tokens masqués. Aucun arbre, aucune étiquette grammaticale, aucune tête, aucun rôle. La question est donc : si la syntaxe est là, où est-elle ?

Slide 5. Qu'est-ce qu'une sonde ?

(~40s) Visuel : schéma de la sonde au-dessus du modèle figé.

La méthode pour répondre s'appelle le *probing*. Le principe : on gèle les paramètres du modèle, on extrait les vecteurs h_i d'une couche cachée, et au-dessus on entraîne un *petit* modèle supervisé — typiquement une simple projection linéaire — à prédire une propriété linguistique annotée. Pourquoi un modèle aussi petit ? Parce que si une projection linéaire suffit, c'est que la propriété est *déjà* encodée géométriquement dans les vecteurs. Une sonde trop puissante apprendrait elle-même la structure — même à partir de vecteurs aléatoires — et on ne saurait plus si l'information vient du modèle ou de la sonde.

Slide 6. La sonde structurelle de Hewitt & Manning (2019)

(~45s) Visuel : formule $\|B(h_i - h_j)\|^2 \approx d_T(w_i, w_j)$ + flèche B des vecteurs aux points projetés.

En 2019, Hewitt et Manning proposent la *sonde structurelle*. L'idée : apprendre une projection linéaire B telle que la distance euclidienne au carré entre deux vecteurs projetés approxime la distance dans l'arbre de dépendances. Visuellement, à droite : on prend les vecteurs bruts de BERT (les points bleus en haut), on les projette par B , et on obtient les points oranges en bas, disposés de manière à ce que leurs distances euclidiennes reflètent l'arbre. La sonde n'a accès qu'aux vecteurs — jamais à la phrase, jamais à l'arbre directement. Si cette projection linéaire fonctionne, alors la syntaxe vit géométriquement dans l'espace des représentations.

Slide 7. Comment évaluer la sonde ? Deux métriques

(~45s) Visuel : scatter plot Spearman + arbre UUAS avec une arête erronée.

Pour mesurer la qualité de la sonde, deux métriques. À gauche, la **corrélation de Spearman** : on regarde si les distances prédites sont dans le *bon ordre* que les distances vraies. C'est une corrélation de rang, calculée sur toutes les paires de mots d'une phrase. On rapporte ρ_{5-50} , moyenne sur les phrases de longueur 5 à 50 mots. À droite, l'**UUAS** : à partir des distances prédites, on construit un arbre couvrant minimum, et on compte la fraction d'arêtes correctes — non étiquetées, non orientées. Dans l'exemple, trois sur quatre arêtes sont correctes, soit $UUAS = 0,75$.

Slide 8. Résultat sur l'anglais

(~30s) Visuel : graphique de barres : Baseline vs BERT-base, UUAS et Spearman.

Voici le résultat principal de Hewitt et Manning sur l'anglais. À droite, BERT-base à la couche 7 : $UUAS = 0,80$, $Spearman = 0,85$. À gauche, le baseline non contextualisé : 0,49 et 0,50. Plus 31 points en UUAS, plus 35 en Spearman — sans aucun entraînement syntaxique. Performance proche des analyseurs syntaxiques entièrement supervisés sur PTB. La syntaxe vit donc bien dans la géométrie de BERT.

Slide 9. Ce que nous ajoutons

(~25s) Visuel : deux questions ouvertes en colonnes.

Hewitt et Manning ont répondu à la question pour BERT en anglais. Nous prolongeons leur travail avec deux questions ouvertes. Premièrement : la même géométrie syntaxique existe-t-elle dans mBERT, pour des langues autres que l'anglais ? Concrètement, ça marche-t-il sur l'espagnol ? Deuxièmement : la syntaxe est-elle une forme *rigide* dans l'espace, ou faut-il l'*amplifier* par des étirements non uniformes ? Pour ces deux questions, deux contributions : une réplique couche par couche sur AnCora, et une *sonde isométrique*.

Slide 10. Données : UD_Spanish-AnCora

(~25 s) *Visuel : partitions du treebank, encodeur, hyperparamètres de la sonde.*

Pour la première question, nous utilisons le treebank UD_SPANISH-ANCORA — la partie espagnole d’AnCora dans Universal Dependencies. Quatorze mille phrases d’entraînement, mille six cents en dev, mille sept cents en test. L’encodeur est mBERT, `bert-base-multilingual-cased`, couvrant 104 langues, complètement figé. La sonde a un rang 128, perte ℓ_1 , 30 époques avec early stopping. L’espagnol amène deux complications absentes du PTB anglais : les *contractions* comme « del = de + el », et les sujets *pro-drop* sous forme de nœuds vides — il faut bien les filtrer pour ne pas polluer la sonde.

Slide 11. Résultat 1 : layer sweep sur l’espagnol

(~40 s) *Visuel : courbe en cloche sur les 13 couches de mBERT.*

Nous balayons les 13 couches de mBERT et entraînons une sonde par couche. Le résultat : une courbe en cloche qui reproduit exactement la forme observée par Hewitt et Manning sur l’anglais. Spearman pique à 0,86 à la couche 7, UAS à 0,76 à la même couche. Donc la syntaxe espagnole se concentre au milieu du réseau, comme en anglais.

Slide 12. Transfert cross-lingue

(~40 s) *Visuel : tableau comparatif H&M vs nous.*

Comparons directement à Hewitt et Manning. Eux, sur PTB anglais : Spearman $\approx 0,85$, UAS $\approx 0,80$. Nous, sur AnCora espagnol via mBERT : Spearman = 0,86, UAS = 0,76. La même couche pique. Spearman est même légèrement plus haut. UAS n’est que 4 points en dessous, malgré la dilution de mBERT sur 104 langues. C’est une forte évidence pour un *sous-espace syntaxique partagé* entre les langues, en accord avec Chi et al. (ACL 2020).

Slide 13. La sonde isométrique

(~45 s) *Visuel : formule $BB^\top = I$ + interprétation rigide vs étirable.*

Passons maintenant à la deuxième question. La sonde linéaire fait deux choses entremêlées : elle *tourne* et elle *étire* l’espace. Notre extension isole ces deux opérations en contraignant la projection à être orthogonale : $BB^\top = I$, c’est-à-dire que B est une rotation pure. Si la syntaxe est une forme rigide dans l’espace mBERT, l’isométrie doit égaler la sonde linéaire. Si la syntaxe nécessite un étirement anisotrope, l’isométrie doit s’effondrer. C’est un test propre, par construction.

Slide 14. Deux scénarios

(~25 s) *Visuel : illustration des deux hypothèses — rigide vs étirable.*

Les deux scénarios qu’on cherche à distinguer. À gauche : si l’arbre est rigide dans le sous-espace, l’isométrie conserve les distances et reproduit le résultat de la sonde linéaire. À droite : si l’arbre est dans une direction *étirée* de faible variance, la rotation pure ne peut pas le récupérer.

Slide 15. Résultat 2 : l’effet Pancake

(~50 s) *Visuel : tableau Linéaire vs Isométrie + interprétation Pancake.*

Le résultat est sans appel. À la couche 7, la sonde linéaire : UAS = 0,76, Spearman = 0,86, nombre de condition $\kappa(B) = 3,74$ — la sonde étire l’espace par un facteur ~ 4 entre ses directions principales. La sonde isométrique, contrainte à être une rotation pure, s’effondre : UAS = 0,27, Spearman = 0,35 — soit **-64 % en UAS**. Interprétation : l’arbre syntaxique espagnol est aplati

dans des directions de *faible variance* de l'espace mBERT. La sonde doit amplifier ces directions par environ 4 pour faire ressortir la structure. C'est ce que nous appelons l'effet *Pancake* : la syntaxe vit dans une crêpe, pas dans une boule.

Slide 16. Limitations

(~25 s) *Visuel : liste des limitations.*

Quelques limites honnêtes. Tous les chiffres sont sur *une seule* graine ; il faudrait répéter avec au moins 5 seeds et reporter moyenne $\pm$ écart-type. Le test set n'a pas été touché, par discipline. Une tâche de contrôle à la Hewitt-Liang aborderait la question de la capacité intrinsèque de la sonde. Et il faudrait comparer contre des encodeurs espagnols monolingues comme BETO, pour quantifier le coût de la dilution multilingue de mBERT.

Slide 17. Du probing syntaxique au probing multimodal

(~40 s) *Visuel : tableau de correspondances syntaxe $\rightarrow$ multimodal.*

Comment ce travail se relie-t-il au doctorat sur le raisonnement multimodal sur vidéo ? La méthodologie — sonde plus diagnostic géométrique — se généralise directement. Mêmes questions, autres propriétés : où vit chaque modalité dans un MLLM ? Sont-elles rigidement préservées, c'est-à-dire κ proche de 1 quand on isole chacune ? À quelle couche se cristallise leur interaction, et observe-t-on un effondrement modal analogue à l'effet Pancake ? Cela connecte avec les travaux récents sur le *modality collapse* (Park et al., AACL 2025 ; Wang et al., CVPR 2025). Même méthodologie, dimension supérieure.

Slide 18. À retenir

(~30 s) *Visuel : trois points résumés.*

Trois choses à retenir.

Premièrement, nous avons répliqué la sonde structurelle en espagnol — UUAS 0,76 à la couche 7, à seulement 4 points du pic anglais. Forte évidence d'un sous-espace syntaxique cross-lingue.

Deuxièmement, nous avons documenté trois pièges méthodologiques de réplification qui empoisonnaient silencieusement le pipeline (nœuds vides, ponctuation espagnole, indexation des couches) : leur correction donne +51 % d'UUAS.

Troisièmement, nous avons introduit la *sonde isométrique*. La chute de -64% d'UUAS montre que la géométrie syntaxique espagnole est *étirable*, *pas rigide* : effet « Pancake », $\kappa(B) = 3,74$.

Merci. Je reste à votre disposition pour les questions.