


Les *transformers* (type BERT) encodent-ils la syntaxe d'une langue ?

Marcos Lahoz Yague

Le langage est *arborescent*

On représente une phrase comme un **arbre de dépendances** :

- chaque mot a **exactement un mot-tête** — le mot dont il dépend grammaticalement ;
- la seule exception est la **racine**, sans tête, typiquement le verbe principal ;
- chaque arête porte une étiquette (*nsubj*, *obj*, *det*...) qui nomme la relation grammaticale.




Dependency tree of the sentence: The cat ate the fish.

Deux métriques naturelles sur l'arbre

Avec cette définition de la syntaxe (un arbre de dépendances), on associe à chaque phrase **deux quantités numériques** naturelles.

1. Profondeur d'un mot $\text{depth}_T(w_i)$

Nombre d'arêtes du mot jusqu'à la racine.




Position dans la hiérarchie. Le verbe principal est toujours à 0.

2. Distance entre deux mots $d_T(w_i, w_j)$

$d_T(w_i, w_j)$

Nombre d'arêtes du chemin unique qui les relie.



$$d_T(\text{cat}, \text{fish}) = 2, \quad d_T(\text{The}, \text{book}) = 3, \\ d_T(\text{The}, \text{the}) = 4.$$

Hewitt & Manning (NAACL 2019) : ce qu'ils essaient

Ils s'attaquent à **la même question**, dans un cadre concret :

- Encodeur : **BERT-base** (12 couches, 768 dim, figé).
- Langue : **anglais**.
- Treebank : Penn Treebank (Wall Street Journal).


Question opérationnelle : peut-on retrouver les distances d_T à partir des vecteurs contextuels ?

Probing structurel : setup

- Modèle **figé**.
- Sonde **linéaire** sur un cachée.

$$\|B(h_i - h_j)\|_2^2 = \hat{d}_{ij} \approx c$$

Projection linéaire B apprise par ℓ_1 sur les distances de l'arbre. Sans supervision : les distances d_T . Il n'accède qu'aux vecteurs.



Évaluer la sonde (1/2) : Spearman ρ

Pour chaque mot w_i , on compare l'ordre de deux listes :

$\{\hat{d}(w_i, w_j)\}$ vs $\{d_T(w_i, w_j)\}$.

$$\rho_i = 1 - \frac{6 \sum_{j \neq i} (\text{pos}_{\hat{d}}(w_j) - \text{pos}_{d_T}(w_j))^2}{n(n^2 - 1)}$$

pos : position de w_j dans l'ordre croissant des distances vers w_i .

$\rho = +1$: ordres identiques. $\rho = -1$: opposés.

Le coefficient final est une moyenne ρ_{5-50} sur les ρ_i (voir *backup pour les détails*).

Exemple : depuis « ate »

w_j	d_T	$\hat{d}$
cat	1	0,8
fish	1	1,2
The	2	1,9
the	2	2,1


Valeurs différentes,
même ordre $\Rightarrow \rho_i = 1$.

Évaluer la sonde (2/2) : UUAS

Unlabeled Undirected Attachment Score


Recette :

- À partir de $\hat{d}$, construire un **arbre couvrant minimum**.
- Comparer ses arêtes à celles de l'arbre vrai.
- **UUAS** = fraction d'arêtes correctement retrouvées.



Ex. : 3 sur 4 = 0,75.

Résultat de H&M sur l'anglais : OUI



⇒ la syntaxe *vit* dans la géométrie de BERT.

Ce que nous ajoutons


Hewitt & Manning ont répondu à la question sur **BERT anglais**. Deux suites naturelles restent ouvertes :

1. **Transfert cross-lingue**. La même géométrie syntaxique existe-t-elle dans **BERT multilingue** pour des langues autres que l'anglais ? Concrètement : fonctionne-t-elle sur **l'espagnol** via mBERT ?
2. **Forme rigide ou directions à amplifier** ? L'arbre syntaxique est-il déjà présent comme une **figure géométrique rigide** dans l'espace de BERT (la sonde n'a qu'à *tourner*), ou est-il codé dans **certaines directions** que la sonde doit *étirer* pour le rendre lisible ?

Nos deux contributions répondent à ces deux questions :

- Réplication couche par couche sur UD_Spanish-AnCora.
- **Sonde isométrique** — une variante contrainte qui isole la rotation de l'étirement.

Résultat 1 — la syntaxe espagnole pique à la couche 7



- Courbe en cloche reproduisant celle de Hewitt-Manning sur l'anglais.
- Meilleure couche 7 : **Spearman** 0,860, **UUAS** 0,760.

Transfert cross-lingue : seulement -4 points d'UUAS

	H&M (BERT anglais, PTB)	Nous (mBERT, AnCora)
Meilleure couche	7-8	7
Spearman distance	0,850	0,860
UUAS	0,798	0,760
Rang de la sonde	128	128

- Même organisation en cloche sur les couches, pic décalé d'au plus une couche.
- Spearman *légèrement plus haut* en espagnol ; UUAS seulement 4 points en dessous, malgré la dilution multilingue de mBERT sur 104 langues.
- Forte évidence pour le **sous-espace syntaxique indépendant de la langue** (Chi et al., ACL 2020).

Contribution : la sonde *isométrique*

La sonde linéaire **tourne et étire** l'espace mBERT. Deux opérations entremêlées.

Question : laquelle compte ?


Sonde isométrique : contraindre la projection à être orthogonale.

$$B_{\text{iso}} B_{\text{iso}}^{\top} = I_r \quad \implies \quad \kappa(B_{\text{iso}}) = 1, \text{ rotation seule}$$


$\kappa(B)$ = *nombre de condition* : rapport entre la plus grande et la plus petite valeur singulière de B .

$\kappa = 1$: rotation pure, aucun étirement. $\kappa \gg 1$: la sonde *étire* fortement certaines directions par rapport aux autres.

Deux scénarios — ce que l'expérience peut distinguer



Si la syntaxe est une **forme rigide** dans l'espace mBERT → l'isométrie doit **égaler** la sonde linéaire.



Si la syntaxe nécessite un **étirement anisotrope** → l'isométrie **s'effondre**.

Résultat 2 — la syntaxe espagnole *n'est pas* une forme rigide

Sonde (couche 7)	Spearman	UUAS	$\kappa(B)$
Linéaire	0,860	0,760	3,74
Isométrique	0,355	0,272	1,00
Δ relatif	−59%	−64%	—

Contraindre la sonde à être **orthogonale** effondre les performances : −64% d'UUAS et −59% de Spearman.

Spectre singulier de B : $\sigma_{\max}=0,44$, $\sigma_{\min}=0,12$, donc $\kappa = 3,74$ (*anisotropie modérée*).

Interprétation : l'effet *Pancake*

L'arbre syntaxique espagnol est **aplati** dans des directions de faible variance de l'espace mBERT. La sonde doit les *amplifier* ($\sim 4\times$) pour faire ressortir la structure de l'arbre.

Du *probing* syntaxique au *probing* multimodal

La sonde + diagnostic géométrique développée ici se généralise **directement** aux modèles multimodaux.

Mêmes questions, autre propriété :

- Où vit chaque modalité (vision, audio, texte) ?
- Sont-elles *rigidement* préservées (κ élevé en isolant chacune) ?
- À quelle couche l'interaction se cristallise — et observe-t-on un *effondrement modal* ?

Connecte avec les phénomènes de *modality collapse* rapportés par **Chaudhuri et al. ICML 2025**.

Ce travail	⇒	doctorat
Aujourd'hui (syntaxe)		Doctorat (multimodal)
couches mBERT		couches MLLM
axes syntaxiques		axes par modalité
effet Pancake		modality collapse
$\kappa(B)$		κ modal
arbre UD		raisonnement vidéo-QA

Même méthodologie, dimension supérieure.

Backup

slides supplémentaires — réponses anticipées

Backup — Formule exacte de ρ_{5-50}

Spearman ρ_i (per-mot) : pour chaque mot w_i , corrélation de rang entre les distances prédites et les vraies vers les autres mots.

$$\rho_i = 1 - \frac{6 \sum_{j \neq i} (\text{pos}_{\hat{d}}(w_j) - \text{pos}_{d_T}(w_j))^2}{n(n^2 - 1)}$$

n : longueur de la phrase. pos : position de w_j dans l'ordre croissant.

1. Moyenne par longueur ℓ . On regroupe *tous* les ρ_i des mots des phrases de longueur ℓ :

$$\bar{\rho}_\ell = \frac{1}{\ell \cdot |\mathcal{S}_\ell|} \sum_{s \in \mathcal{S}_\ell} \sum_{w_i \in s} \rho_i, \quad \mathcal{S}_\ell = \text{phrases de longueur } \ell.$$

2. Macro-moyenne sur les longueurs.

$$\rho_{5-50} = \frac{1}{|L|} \sum_{\ell \in L} \bar{\rho}_\ell, \quad L = \{5, 6, \dots, 50\} \cap \text{longueurs présentes}.$$

Chaque longueur pèse autant, indépendamment du nombre de phrases.

Backup — Données utilisées par H&M : Penn Treebank (PTB)

Penn Treebank (Marcus et al., 1993) — le treebank historique de référence en anglais.

- Wall Street Journal, années 1989–1994.
- ~40 000 phrases annotées en constituants.
- Conversion vers *Stanford Dependencies* (de Marneffe et al., 2006).
- Partitions standard : sections 02–21 (train), 22 (dev), 23 (test).

Pourquoi PTB pour H&M ?

- Standard de facto pour le parsing en anglais.
- Annotations de très haute qualité.
- Permet la comparaison directe avec les analyseurs syntaxiques entraînés.

H&M testent aussi sur *English Web Treebank* (UD anglais) — résultats similaires.

Backup — Données : UD_Spanish-AnCora

Treebank. Partie espagnole d'AnCora (Taulé et al. 2008), distribuée via Universal Dependencies (CC BY 4.0). Texte journalistique, annotations en dépendances.

partition	phrases	lignes
train	14 287	453 039
dev	1 654	53 476
test	1 721	53 622

Encodeur.

bert-base-multilingual-cased
(mBERT) — 104 langues, figé. 12 couches
transformer + couche d'entrée.

Sonde. Rang $r=128$, perte ℓ_1 , Adam, 30
époques, early stopping (patience 4). Une
seule graine.

Backup — L'architecture *transformer* (Vaswani et al., 2017)

Idée centrale : *self-attention*.

Pour chaque token i :

$$h_i = \sum_j \alpha_{ij} Vx_j, \quad \alpha_{ij} = \text{softmax}_j \left(\frac{(Qx_i)^\top (Kx_j)}{\sqrt{d}} \right)$$

Q, K, V : matrices apprises (*query, key, value*).

Bloc transformer :

- Multi-head self-attention
- Feed-forward (MLP par token)
- Résidu + LayerNorm

Empilé N fois.

Encoder-only

(BERT)

12 blocs identiques.

Chaque token *voit tous les autres* dans les deux directions.

Sortie : $h_i \in \mathbb{R}^{768}$ par token.

Backup — BERT en détail

Architecture

- Encoder-only transformer
- BERT-base : 12 couches, 768 dim, 110 M paramètres
- BERT-large : 24 couches, 1024 dim, 340 M paramètres

Pré-entraînement

- *Masked Language Modeling* : 15 % des tokens masqués
- *Next Sentence Prediction*
- 3,3 milliards de mots (Wikipedia EN + BookCorpus)

Tokenisation : WordPiece (sous-mots).

Ex : playing $\rightarrow$ play, ##ing.

Tokens spéciaux

- [CLS] : début, classification
- [SEP] : séparateur
- [MASK] : à prédire

Sortie : $h_i \in \mathbb{R}^{768}$ par token, contextuelle.

Backup — mBERT (bert-base-multilingual-cased)

Différences avec BERT :

- Vocabulaire WordPiece partagé sur **104 langues** ($\sim 120k$ tokens)
- Données : Wikipedia de 104 langues
- Échantillonnage exponentiellement lissé (boost des langues à faible ressource)
- **Aucune supervision cross-lingue explicite** (pas de paires alignées)
- Architecture identique à BERT-base : 12 couches, 768 dim

Résultat surprenant. mBERT développe un **sous-espace syntaxique partagé** entre les langues, sans qu'on le lui ait demandé (Pires et al. 2019, Chi et al. 2020, ce travail).

Hypothèse : la contrainte de capacité partagée force le modèle à factoriser ce qui est universel.

Backup — Pourquoi la sonde de *distance* et pas de profondeur ?

H&M proposent deux sondes :

$$\|B(h_i - h_j)\|_2^2 \approx d_T(w_i, w_j) \quad (\text{distance})$$

$$\|Bh_i\|_2^2 \approx \text{depth}_T(w_i) \quad (\text{profondeur})$$

Pourquoi nous concentrer sur la distance :

1. **Plus de signal** : $O(n^2)$ paires par phrase contre $O(n)$ profondeurs — même quantité de données, plus de supervision.
2. **Sens géométrique** : la sonde isométrique pose une question sur la *métrique* (préservation des distances). La profondeur est une norme depuis l'origine, pas une métrique.
3. **Métrique standard** de la littérature dérivée (Chi 2020, Reif 2019, Limisiewicz 2020).

Notre code (ParseDepthTask) supporte la profondeur — étude complémentaire à faire.

Backup — Pourquoi la couche 7 (et pas la 6) ?

Couche	Spearman	UUAS
6	0,855	0,785
7	0,860	0,760

- Sélection de couche par **Spearman** — protocole H&M.
- Spearman = corrélation directe avec l'objectif d'entraînement (ℓ_1 sur les distances).
- UUAS = métrique *dérivée* (construction d'un MST, perte de l'information continue).
- Sélectionner par UUAS = optimiser une métrique secondaire $\Rightarrow$ *p-hacking*.
- Avec une seule graine, le pic UUAS est plus bruité ; Spearman est plus stable.

Backup — Pourquoi un rang $r = 128$?

Choix : $r = 128 \ll d = 768$.

Comparaison avec H&M :

- H&M balayent r jusqu'à 1024 mais montrent que la performance **sature autour de** $r = 64$ –128 pour BERT-base.
- Notre $r = 128$ reproduit ce choix optimal.

Justification :

- Reste une vraie projection à basse dimension, pas un autoencodeur.
- Réduit le risque de sur-paramétrisation (la sonde apprenant elle-même).
- Cohérent avec le principe de *petit modèle*.

À refaire : sweep de rang ($r \in \{8, 32, 64, 128, 256, 512\}$) avec multi-seed pour vérifier que le choix n'est pas critique.

Backup — La tâche de contrôle (Hewitt & Liang, EMNLP 2019)

Question : la sonde apprend-elle à partir de la représentation, ou pourrait-elle apprendre toute structure aléatoire ?

Méthode :

1. Pour chaque *type* de mot, fixer une étiquette aléatoire (consistante).
2. Entraîner la même sonde sur ces étiquettes aléatoires.
3. Mesurer la **sélectivité** = $\text{perf}(\text{vraie tâche}) - \text{perf}(\text{contrôle})$.

Interprétation :

- Sélectivité haute : la sonde exploite vraiment la structure linguistique.
- Sélectivité basse : la sonde est trop puissante.

Notre cas : pas encore fait. Limite reconnue dans les slides « Limitations ».

Backup — Alternatives à mBERT pour l'espagnol

Encodeurs espagnols monolingues :

- **BETO** (Cañete et al., 2020) : BERT-base entraîné sur *Spanish Unannotated Corpora* (~ 3 milliards de mots).
- **RoBERTa-bne** (BSC, 2022) : RoBERTa-large sur 570 Go de texte espagnol (Biblioteca Nacional de España).
- **MarIA** (BSC, 2022) : famille de modèles GPT-2 et RoBERTa.

Hypothèse à tester :

- Plus de paramètres dédiés à l'espagnol $\Rightarrow$ géométrie syntaxique probablement plus nette.
- Quantifier le *coût de la dilution multilingue* de mBERT.

Statut : pas mesuré — extension naturelle du travail.

Backup — Géométrie des arbres dans l'espace euclidien

Problème : les arbres ne s'embedent pas isométriquement en euclidien standard.

Théorème de Bourgain : tout espace métrique fini de n points s'embed dans $\mathbb{R}^d$ avec distortion $O(\log n)$.

Astuce de H&M : utiliser la **distance euclidienne au carré**.

$$\|Bh_i - Bh_j\|_2^2 \approx d_T(w_i, w_j)$$

La distance *au carré* correspond à une forme bilinéaire $h^\top M h$ avec $M = B^\top B$ semi-définie positive.

Lien : les arbres s'embedent naturellement en géométrie hyperbolique (Khrulkov, Sala et al.). La sonde euclidienne est une approximation efficace.

Backup — Le coût du préentraînement BERT

BERT-base (110 M paramètres) :

- Wikipedia EN + BookCorpus ($\sim 3,3$ milliards de mots).
- 4 jours sur 4 Cloud TPU (16 chips).
- Coût estimé : ~ 500 \$ (preemptible) à $\sim 7\,000$ \$ (on-demand, Strubell et al. 2019).

BERT-large (340 M paramètres) : $\sim 60\,000$ \$.

mBERT : Wikipedia de 104 langues, taille totale comparable. Mêmes hyperparamètres que BERT-base.

Notre coût : 0 en préentraînement (modèles réutilisés). Sondes entraînées sur GPU consumer (G4 sur Colab, ~ 3 h pour le sweep complet).

Backup — Le *modality collapse* dans les MLLMs

Phénomène : dans les Multimodal LLMs, l'information distinctive de chaque modalité **s'efface** après quelques couches d'intégration.

Référence récente :

- Chaudhuri, Dutta, Bui & Georgescu, ICML 2025 — *A Closer Look at Multimodal Representation Collapse*.

Analogie avec l'effet Pancake :

- Syntaxe : la structure d'arbre vit dans une direction *aplatie* de l'espace mBERT.
- Multimodal : chaque modalité vit dans une direction qui s'aplatit progressivement, jusqu'à devenir indistinguable.

Hypothèse : la sonde isométrique + diagnostic κ pourrait *quantifier* le collapse couche par couche.

Backup — Comment opérationnaliser « modalité » pour probing ?

Quatre définitions possibles :

1. **Signal d'entrée** (pixels, ondes, tokens) — trivial, observable mais peu informatif.
2. **Encodeur dédié** (vision, audio) — structurel mais ignore l'intégration.
3. **Sous-espace dans les représentations** après cross-attention — où le *probing* entre.
4. **Capacité comportementale** (réussir une tâche modal-spécifique) — outcome-driven, indirect.

Probing visera surtout (3) : isoler le sous-espace dédié à chaque modalité dans les couches d'un MLLM.

Méthodologie identique à ce travail :

- Sonde linéaire prédisant la présence/contenu d'une modalité.
- Sonde isométrique pour tester la rigidité du sous-espace.
- $\kappa(B)$ comme diagnostic d'aplatissement.