

La syntaxe espagnole se cache-t-elle dans mBERT ?


Sondes structurelles et extension isométrique

Marcos Lahoz Yago

Université Paris-Saclay

Orange Research — 13 mai 2026

Le squelette syntaxique : l'arbre de dépendances



« The student read the book yesterday. »

$$d_T(\text{read}, \text{student}) = 1$$

$$d_T(\text{The}, \text{book}) = 3$$

$$d_T(\text{The}, \text{the}) = 4$$

- Chaque mot a exactement **une tête** (la racine n'en a aucune).
- Les arêtes portent des étiquettes fonctionnelles (nsubj, obj, ...) — mais **H&M les ignorent** : seule la topologie compte.
- La **distance d'arbre** $d_T(w_i, w_j)$ est le nombre d'arêtes du chemin unique entre deux mots.

Cet arbre est l'objet de référence : on demandera aux représentations de mBERT

« Syntaxe » : que mesure-t-on exactement ?

Le mot *syntaxe* recouvre plusieurs notions distinctes. La sonde structurelle de Hewitt & Manning n'en mesure **qu'une seule**.

Mesuré (H&M)

- Topologie de l'arbre de dépendances UD (non étiqueté, non orienté).

Hors du cadre

- Étiquettes des arêtes (nsubj, obj, ...)
- Structure de constituants (NP, VP, PP, ...)
- Mouvement, liage, contraintes d'îles
- Accord à longue distance (sujet-verbe)
- Grammaticalité — ce qui n'est *pas* permis

L'hypothèse exacte de Hewitt & Manning (2019)

$$\|B(h_i - h_j)\|_2^2 \approx d_T(w_i, w_j)$$

Lecture des symboles

- $h_i, h_j \in \mathbb{R}^d$: vecteurs contextuels de mBERT (couche fixée, $d=768$).
- $B \in \mathbb{R}^{r \times d}$: projection **linéaire** apprise ($r=128 \ll d$).
- d_T : distance de graphe dans l'arbre UD annoté.

Trois affirmations dans une seule formule

- **Linéaire.** Si une projection *linéaire* suffit, la syntaxe est **déjà là** dans la représentation — ce n'est pas la sonde qui l'invente. Une MLP profonde la trouverait même dans des vecteurs aléatoires.
- **Sous-espace de basse dimension** ($r \ll d$). La syntaxe ne nécessite pas les 768 axes : elle vit sur une petite ardoise dans l'espace mBERT.
- **Métrique géométrique.** Pas seulement « information disponible » : les distances euclidiennes au carré *approximent* les distances d'arbre. Une structure discrète embarquée comme une métrique continue — **c'est le**

L'arbre « vrai » est une convention, pas la vérité

L'arbre de référence est ce qu'une équipe d'annotateurs (Taulé et al., Universitat de Barcelona, AnCora 2008) a marqué en suivant les conventions **Universal Dependencies**.
Choix spécifiques :

- Les *contractions* espagnoles ($del = de + el$) : représentées comme deux nœuds sous un rang composite.
- Les sujets *pro-drop* : représentés comme des nœuds vides explicites.
- La place de la copule (*ser, estar*) : tête ou dépendant ?
- L'attachement des modificateurs ambigus (PP-attachment).

D'autres formalismes (HPSG, LFG, grammaire de constituants) donneraient des arbres *partiellement différents* pour la même phrase.